

《膳食搭配智能体系统》

系统设计说明书

团队名称	海底小纵队
团队成员	052401304 李思淇、102301228 林郑嘉同、102401108 李铭媛、102401202 洪雅琳、102401307 陈媛、102401402 冯安娜、102401405 王怡婷、102401406 陈婉凤、102401409 陈宝荣、102401411 陈博淇、102401604 马英慧
文档版本	V1.0
编制日期	2026-11-08
编制人	海底小纵队

依从 GB/T 8567—2006

表 1: 迭代记录表

版本	日期	修改人	修改内容
V0.1	2026-11-04	李铭媛	建立文档骨架
V0.2	2026-11-04	海底小纵队	根据产品方案 v1.0 攥写初稿
V0.3	2026-11-08	海底小纵队	根据产品改进设想调整系统设计
V1.0	2026-11-08	李铭媛	全文去重与结构梳理

目录

1 注解 **1**

2 引言 **2**

2.1 标识 2

2.2 系统概述 2

2.3 文档概述 2

3 引用文件 **2**

4 系统级设计决策 **3**

4.1 设计决策 3

4.2 设计约定 3

4.3 行为约束 4

5 系统体系结构设计 **5**

5.1 系统总体设计 5

5.1.1 概述 5

5.1.2 设计思想 6

5.1.3 关键技术与算法 7

5.1.4 关键数据结构 8

5.1.5 基本处理流程 10

5.1.6 人工处理过程 11

5.2 系统部件 12

5.3 执行概念 12

5.4 接口设计 14

5.4.1 接口标识 14

5.4.2 用户接口 14

5.4.3 外部接口 14

5.4.4 流式对话协议（SSE） 15

5.4.5 内部接口 16

6 运行设计 **17**

6.1 系统初始化 17

6.2 运行控制 17

6.3 运行结束 18

7 系统出错处理设计 **18**
7.1 出错信息 18
7.2 补救措施 19

8 系统维护设计 **20**
8.1 检测点的设计 20
8.2 检测专用模块的设计 20
8.2.1 健康检查接口 20
8.2.2 数据库验收脚本 21
8.2.3 结构化日志 21
8.2.4 监控指标 21
8.2.5 回归测试脚本 21

9 尚待解决的问题 **21**

10 需求的可追踪性 **22**

1 注解

缩略语按字母序见表 2，术语与定义见表 3。

表 2: 缩略语（按字母序）

缩略语	含义
BMR	基础代谢率
DBDD	数据库（顶层）设计说明
DRIs	膳食营养素参考摄入量
MVP	最小可行产品
PAL	身体活动水平系数
RAG	检索增强生成（领域知识库检索辅助大模型回答）
RNI	推荐摄入量
RRF	倒数排名融合：按多路检索排名合并结果
SSDD	系统/子系统设计（结构）说明
SSE	服务器推送事件（流式传输）
UL	可耐受最高摄入量

表 3: 术语与定义

术语	定义
Function Calling	工具调用：智能体调用外部函数完成确定性计算
data_quality	数据可信度：official（官方实测）/ approx（估算）/ check（待核查）
宏量/微量营养素	宏量：碳水、蛋白质、脂肪；微量：维生素、矿物质
意图路由	将用户请求分流至询问 / 配餐 / 调整三类路径
候选	每餐的多个候选方案
反向营养	由症状推测可能缺乏的营养素
生重/成品口径	食材按未烹饪生重计 / 菜式按烹饪后成品计

术语	定义
IF-INT-T01～T12	后端与 Agent 间的 12 个工具接口
接口标识	三段式：IF-UI（用户）/ IF-EXT（外部）/ IF-INT（内部）
错误码分段	0 成功 / 10xx 参数权限 / 20xx 计算依赖 / 3001 内容安全
存活/就绪探针	`/health/live` 仅证进程存活；`/health/ready` 要求依赖全就绪

2 引言

2.1 标识

本文档适用的系统为「膳食搭配智能体系统」，软件版本为 V1.0（MVP 最小可行产品）。本文档为该系统的系统/子系统设计（结构）设计说明书（SSDD），文档版本 V1.0。

2.2 系统概述

膳食搭配智能体系统以用户自定范围为规划单位，面向有意识调控饮食、以自行烹饪为主的用户。系统以「营养素配比平衡」为核心，采用「营养搭配 → 菜式转化」两步模型，将食材层的个性化营养方案转化为菜式层的可执行家常菜菜单，并标注依据来源。

系统以**对话为唯一入口**，用户以自然语言表达需求，智能体通过意图路由理解「询问 / 配餐 / 调整」三类意图，编排确定性工具生成个性化食谱，并以餐卡、食材清单等结构化形态呈现结果。对话右侧设工具栏，作为 Agent 输出的结构化视图。档案为轻量可选项，可随对话逐步补全。

本项目为福州大学软件工程课程作业，由「海底小纵队」团队开发；系统为首次开发（无历史版本），运行于本地部署环境，经现代浏览器访问。

2.3 文档概述

本文档为系统级（概要）设计说明书，描述系统的设计基线、设计决策、体系结构、运行与出错处理、维护与可追踪性等，作为后续详细设计与编码实现的对齐依据。预期读者为课程教师、助教与项目组全体成员。

本系统涉及健康数据（过敏原、疾病史、饮食禁忌等），属私密信息，其访问控制与权限设计须单独关注。

3 引用文件

本文档引用的文件及其版本见表 4。

表 4: 引用文件

编号	文件
1	GB/T 8567—2006 计算机软件文档编制规范
2	GB/T 9385—2008 计算机软件需求规格说明规范
3	GB/T 11457—2006 信息技术软件工程术语
4	膳食搭配智能体系统软件需求规格说明书（内部文档）
5	膳食搭配智能体系统数据库设计说明书（DBDD，内部文档）
6	中国居民膳食指南（2022 版）
7	中国居民膳食营养素参考摄入量（2023 版）
8	中国食物成分表（标准版，2018 版）

4 系统级设计决策

4.1 设计决策

1. **输入/输出形态**：以对话为唯一入口；输出结构化结果与正文解释，并附来源标注与就医提示。
2. **生成主体**：候选食谱由**确定性工具**计算生成，Agent 负责理解需求、编排工具、决策与解释。
3. **生成单位**：以用户自定范围生成；每餐 = 主食 + 1–2 道菜；每餐 2–3 候选，固定后本方案内锁定只读。
4. **营养口径**：能量目标 = BMR × 活动系数，仅作份量量级参考、**不做热量缺口/盈余**；7 关键微量跨日动态平衡；宏量按餐灵活分配（口径详见 5.1.3）。
5. **约束分级**：饮食禁忌作为硬约束予以排除；候选从全量食材库中生成。
6. **数据存储**：采用 PostgreSQL + pgvector；数据按 core / knowledge / app / audit 四 schema 组织；档案为轻量结构、可随对话补全。
7. **安全保密**：JWT 鉴权；数据库四 schema 权限分离（应用连接非超级用户，core/knowledge 只读、app 读写）；健康数据仅授权用户可见。
8. **写入边界**：所有会修改数据的操作必须经确定性工具执行；Agent 不得自行计算数值、亦不得直接写库；反向营养仅作推测、附就医提示。

4.2 设计约定

本系统统一遵循以下设计约定，作为多人协作与前后端对齐的口径：

表 5: 设计约定

类别	约定
命名	1. 表 / 视图 / 函数按 core（食材 / 菜 / 营养素 / 规则）、knowledge（知识库）、app（业务表 / 视图 / 函数）、audit（导入批次 / 质量）四 schema 组织； 2. 路由统一加 `/api` 前缀； 3. 工具编号 IF-INT-T01～T12。
接口	1. 响应体统一为 JSON 对象，含 `code`（整型错误码）、`message`（字符串提示）、`data`（业务数据）三字段； 2. 接口按三段标识：IF-UI（用户）/ IF-EXT（外部）/ IF-INT（内部）。
数据	1. `null` 表示未知； 2. 可信度 `data_quality` 分三级：官方实测 / 估算 / 待核查； 3. 过敏原三态（已确认含 / 不含 / 未核查）与菜级决策三态（可用 / 严格排除 / 待核查排除）不可混用； 4. `*_complete=false` 表示字段缺失（不当 0）； 5. `production_ready=false` 表示不可用于正式结果。
智能体	1. 遵守 4.3 行为约束。
时间单位	1. 时延目标用 s / ms 表述； 2. 营养目标用「周 / 跨日」表述。

4.3 行为约束

以下 8 条行为约束为系统级关键性需求，对话 Agent 在理解、编排、决策与解释时须全部遵守：

1. **零编造**：所有数值一律来自工具返回值或输入的候选字段，绝不自行计算、编造、估算。
2. **null ≠ 0**：字段为 null 表示未知，不得当 0、不得据此判达标/超标。
3. **data_quality 语义**：仅「官方实测」可作实测依据；「估算」「待核查」不得据此下结论。
4. **未核查 ≠ 安全**：过敏原状态字段 `allergen_status` 为未核查的食材/菜式不得宣称「安全」。
5. **可溯源**：营养结论标注出处；知识性结论用 RAG 检索并注明来源。
6. **硬约束优先**：过敏/忌口/疾病是硬约束，优先于用户偏好，建议不得越界。
7. **needs_clarification**：为 true 时必须追问用户，不得自行取值。

8. **不做医学诊断**：反向营养结果仅作参考线索，须附就医提示。

5 系统体系结构设计

5.1 系统总体设计

5.1.1 概述

5.1.1.1 功能描述

系统由三部分构成，各部分功能如下：

- **对话主界面**：唯一入口，含会话历史、对话流与输入框。
- **结构化输出面板**：工具栏四面板，即食材清单、当前规划、历史方案与膳食报告。
- **轻量档案**：记录身体参数、健康目标、过敏与禁忌；可随对话逐步补全，信息不足时系统追问。

系统性能要求：候选生成 P95 $\leq$ 5s、确定性计算 P99 $\leq$ 100ms、对话首字延迟 $\leq$ 10s、并发 $\geq$ 50 用户；安全性须保证数值可溯源、健康数据仅授权可见。

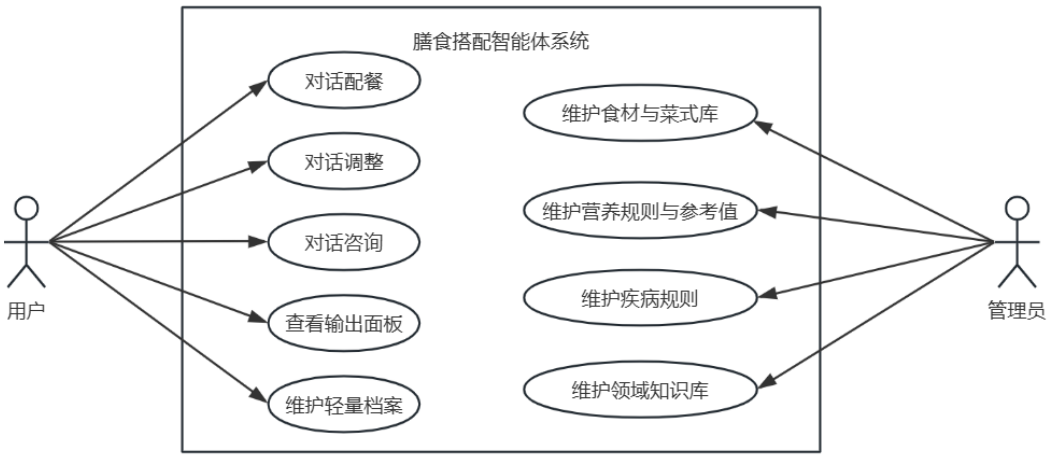


图 1: 用例图

5.1.1.2 运行环境

表 6: 运行环境

层	技术栈
前端	Vue3 + Vite + Element Plus
后端	FastAPI（Python 3.13），REST + 流式 SSE
数据库	PostgreSQL 18 + pgvector 扩展

层	技术栈
Agent 层	Agno 框架
大模型	DeepSeek（生成/对话）；向量化使用共享 embedding 模型

5.1.2 设计思想

系统按「**五层业务架构 + 两个横切层**」组织：五层自上而下逐层调用，初始化层位于底层负责环境准备，评测层贯穿五层负责质量观测。系统分层总览见图 2。各层核心职责见表 7。

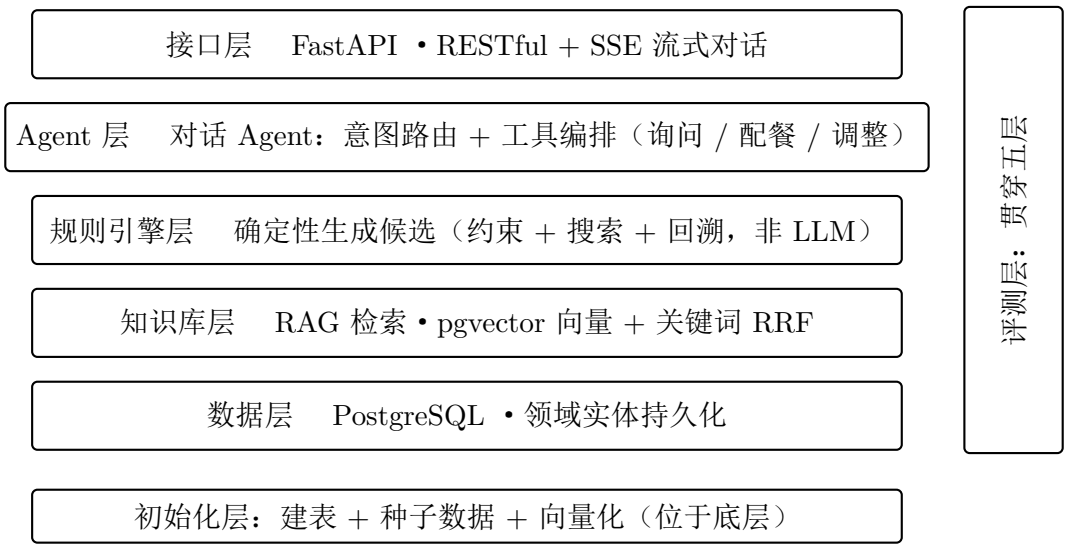


图 2: 系统分层总览

表 7: 各层核心职责

层	核心职责
数据层	数据持久化：档案、食材、菜、方案、会话等实体存储
知识库层	知识检索：权威资料向量化，支撑结论可溯源
规则引擎层	候选生成：确定性计算候选食谱
Agent 层	意图路由与编排：理解自然语言，编排确定性工具完成询问 / 配餐 / 调整
接口层	对外服务：统一 REST API 与流式对话
初始化层	环境准备：建表、灌入种子数据、首次向量化

层	核心职责
评测层	质量观测：量化生成正确性、解释稳定性与性能

五层遵循「上层调用下层、下层不反向依赖上层」：接口层直接面对前端，Agent 层经确定性工具访问规则引擎层与数据层；横切的初始化层与评测层不参与业务调用链。

系统的核心分工是**确定性计算与智能决策分离**：规则引擎（确定性工具）负责计算与生成，Agent 负责理解、决策、沟通；大模型不直接计算数值。据此形成**两层编排**：

- **任务编排归 Agent**：决定何时生成、何时解释、何时调整、何时落库；
- **算法编排归代码**：五步生成、回溯循环等顺序性强且需可复现的计算，封装为确定性工具，仅对外暴露输入/输出契约；Agent 只调用工具并解读结果，不执行循环内部的计算。

领域知识按两路组织：数据形态（食材成分表、菜库、DRIs、微量目标表、禁忌规则）供确定性工具查表计算；**语义形态**（膳食指南、营养原理）供 RAG 检索、Agent 推理与解释。

Agent 定制手段及其作用位置见表 8。

表 8: Agent 定制手段与作用位置

定制手段	作用位置	职责
工具调用	确定性工具	算能量/宏量/微量、禁忌检查、油盐估算、落库、回溯
流程编排	对话 Agent	理解需求、澄清缺口、调工具、解读结果、处理冲突、解释
提示词设计	系统指令 + 行为约束 + 角色设定	边界、输出契约、追问策略、解释表述
领域知识	知识库	数据形态供工具查表，语义形态供 Agent 推理
知识检索	RAG	解释/决策时补来源

系统部署一个**对话 Agent**，以「意图路由 + 工具编排」统一承接询问 / 配餐 / 调整三类请求：询问路径经 RAG 与反向营养分析；配餐与调整路径编排确定性工具生成、换候选与重算。Agent 输出结构化结果与正文解释，其行为须遵守 4.3 行为约束。

5.1.3 关键技术与算法

（1）规则引擎五步生成算法:

1. **算目标**：由档案得能量量级、每餐宏量区间、7 种关键微量目标、硬约束。
2. **构造候选**：一餐 = 主食 + 1–2 道菜；从全量食材库组合出落在该餐宏量区间的候选，同时满足禁忌硬排除、做法规则过滤可行性、油盐在当餐限额内。
3. **候选差异化**：同餐 2–3 个候选靠「换主食材 / 换做法」区分，宏量结构均落在该餐区间。
4. **跨日微量平衡**：读取近期历史方案，汇总 7 种关键微量缺口；不足则回溯补位，直至补齐或落到「参考提示」。
5. **输出**：候选集合 + 每餐「为什么这样搭」+ 微量覆盖进度。

（2）确定性营养计算口径：

- **能量目标**：= BMR × 活动系数，只作份量量级参考，不做热量缺口 / 盈余。
- **健康目标**：只改结构，不改能量总量。
  - 维持：碳水 50–65% / 蛋白 10–20% / 脂肪 20–30%；
  - 减脂：蛋白 18–25%，脂肪压至 20% 下限；
  - 增肌：蛋白 20–25%；
  - 控糖：碳水压至约 50% 下限；
  - 改善肠胃：纤维与发酵食物增多。
- **宏量分配**：按餐由智能体按实际餐位灵活分配，默认三餐参考早 30% / 午 40% / 晚 30%。
- **微量平衡**：7 种关键微量跨日动态平衡，读取近期历史方案；钠归油盐糖控制，膳食纤维归宏量结构，其余微量仅作参考提示。

（3）RAG 知识检索：

- **知识库**：承载《中国居民膳食指南 2022》《中国食物成分表》《DRIs 2023》。
- **检索方式**：向量 + 关键词两路 RRF 混合检索；每条结论标注出处，支撑可溯源。
- **实现路径**：先行关键词检索，随后接入向量 RRF 混合检索。

5.1.4 关键数据结构

系统的关键数据结构（实体）及其用途见表 9，类结构见图 3。

表 9: 关键数据结构

实体	说明
Profile	轻量档案：身体参数、健康目标、疾病/过敏/宗教禁忌三类硬约束
Ingredient	食材库：食材及其营养成分、过敏原标注、数据质量等级

实体	说明
Dish	菜库：可搭配的菜式，带做法与油盐分级
MealPlan	方案主表：一次配餐方案，含起止日期与进度状态
MealSlot	餐位：方案内的一个进食安排（早/午/晚/加餐等），数量与类型由智能体编排
MealCandidate	候选：每个餐位的 2–3 个备选搭配
MealCandidateDish	候选明细：候选里具体包含的一道菜及其份量
ShoppingList	食材清单：按方案汇总出的采购清单
NutritionReport	方案营养报告：一份方案的营养核算结果
SymptomNutritionMap	症状 → 营养素映射：反向营养查询用
Conversation	对话会话：用户与智能体交互的会话窗口，记录基本归属关系
Message	对话消息：会话中的具体记录

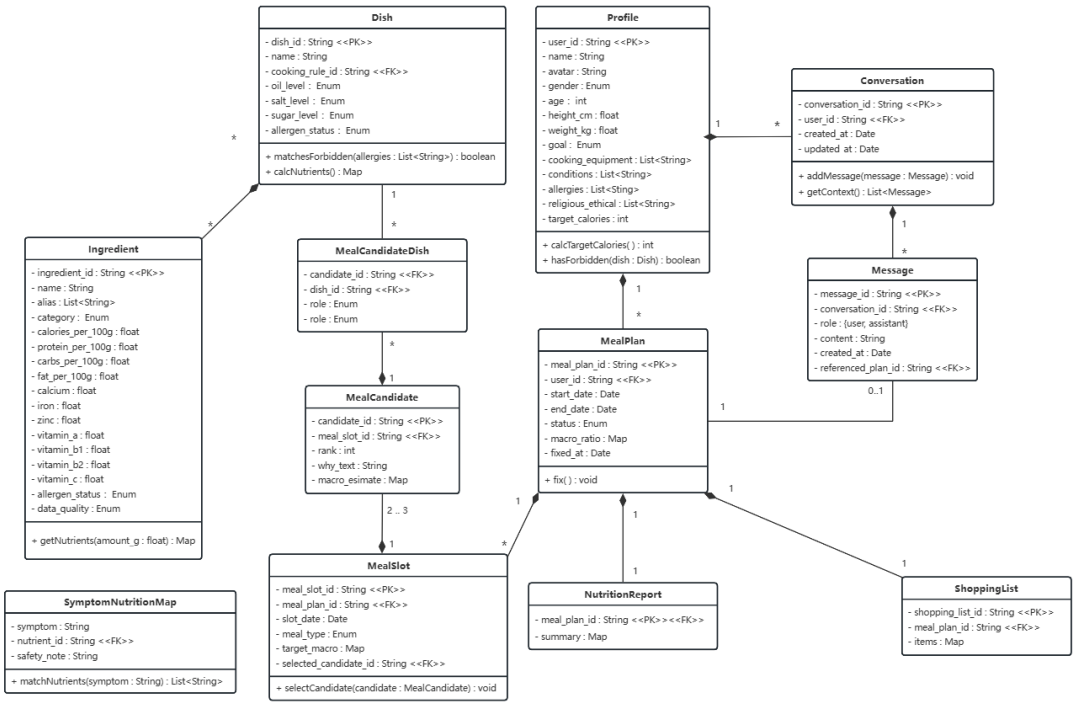


图 3: 类图

5.1.5 基本处理流程

5.1.5.1 系统流程图

配餐生成流程见图 4：用户以自然语言提出配餐需求后，对话 Agent 识别为「配餐」，编排确定性工具生成候选；随后 Agent 解读并解释「为什么这样搭」，结果落库，用户查看餐卡片、换候选或固定。

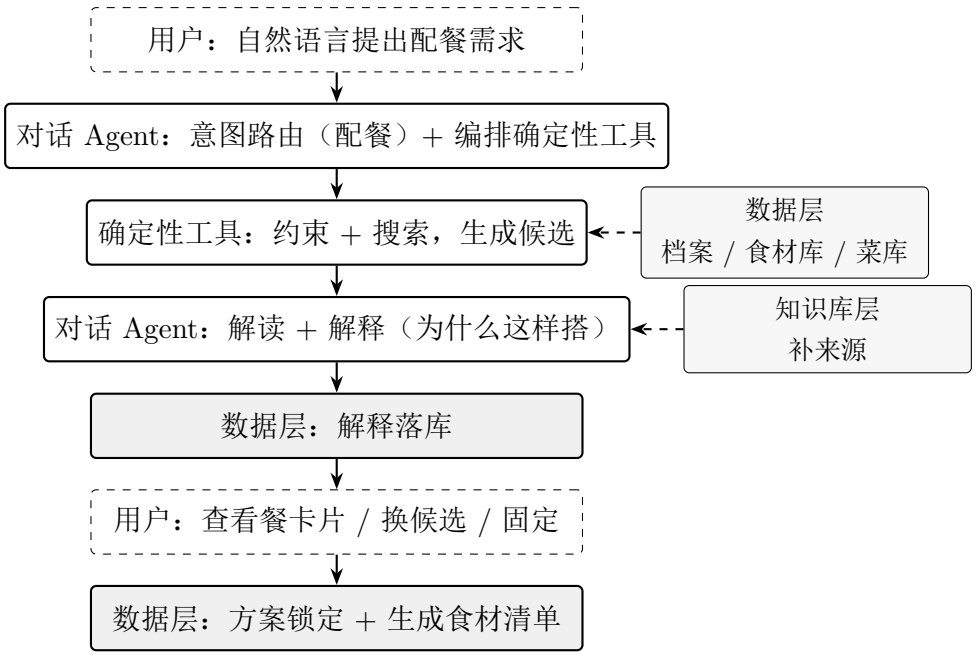


图 4: 配餐生成流程

营养对话流程见图 5：用户以自然语言提问后，对话 Agent 识别为「询问」，读取档案硬约束、执行 RAG 检索与反向营养，前端展示正文与来源标注 / 就医提示 / 跳转定位；该路径只读，不修改方案。

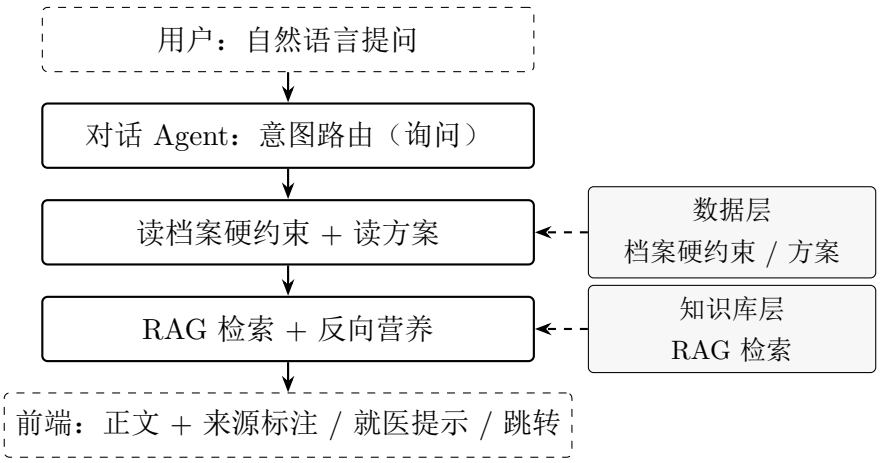


图 5: 营养对话流程

5.1.5.2 数据流程图

核心数据流图如图6所示，以 P1 对话 Agent 为枢纽，涵盖用户经对话与个人档案界面两条入口进入建档、候选生成与固定、营养分析与食材清单输出及咨询问答的数据通路。

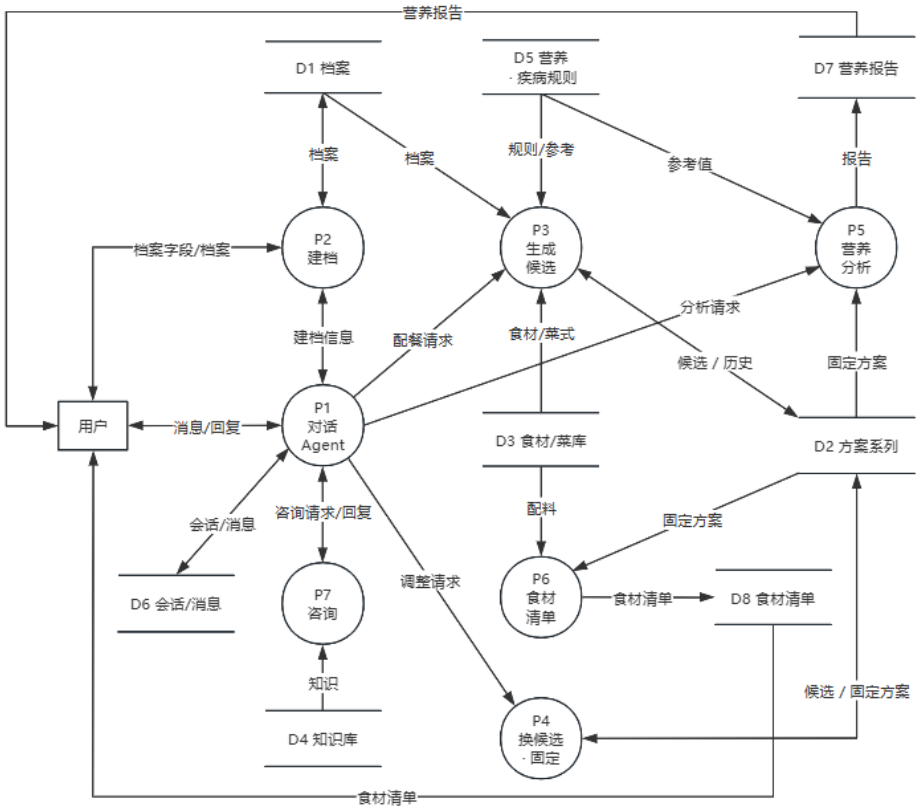


图 6: 系统核心数据流图

5.1.6 人工处理过程

人工处理包括采购、补录档案等；与系统的职责边界见表 10。

表 10: 人工与系统边界小结

环节	系统（自动）	人工（用户）
档案	追问缺失字段、存储与联动生成	口头补充身体参数 / 目标 / 过敏禁忌
配餐	意图路由、五步计算、候选生成	表达生成范围与约束、选择候选并确认
调整	换候选 / 局部重算、维持宏量结构	表达「换一换 / 不吃某食材」等诉求
采购	汇总食材清单、可复制	自行采购、按清单执行

环节	系统（自动）	人工（用户）
营养结论	确定性计算 + RAG 溯源	参考结论、必要时就医

5.2 系统部件

本系统为纯软件系统，所有软件部件均为软件配置项（CSCI）。按 5.1.2 的「五层业务架构」划分部件，每个部件赋予项目唯一标识，并标明用途与开发状态（见表 11）。

部件的静态组成关系为：前端对话界面调用后端服务，后端服务编排对话 Agent 与规则引擎，规则引擎经知识库检索、经数据层持久化，自上而下单向调用、下层不反向依赖上层。

表 11: 系统部件清单

标识	部件	开发状态/类型	用途
CSCI-01	前端对话界面	新开发	对话交互、结构化输出面板、轻量档案入口
CSCI-02	后端服务	复用 + 扩展	REST + SSE 流式对话 + JWT 鉴权
CSCI-03	对话 Agent	新开发	意图路由 + 工具编排，遵守 4.3 行为约束
CSCI-04	规则引擎	新开发	确定性五步生成、营养核算、禁忌与过敏原筛查
CSCI-05	知识库	复用 + 扩展	pgvector 向量 + 关键词 RRF 混合检索，支撑可溯源
CSCI-06	数据库	复用 + 扩展	PostgreSQL 四 schema 持久化；新增方案 / 候选 / 清单表

5.3 执行概念

系统部件间的动态关系通过时序图（图 7）与活动图（图 8）表示。其中，时序图刻画规则引擎一次生成调用的读写时序，活动图刻画对话 Agent 的意图路由与工具编排。

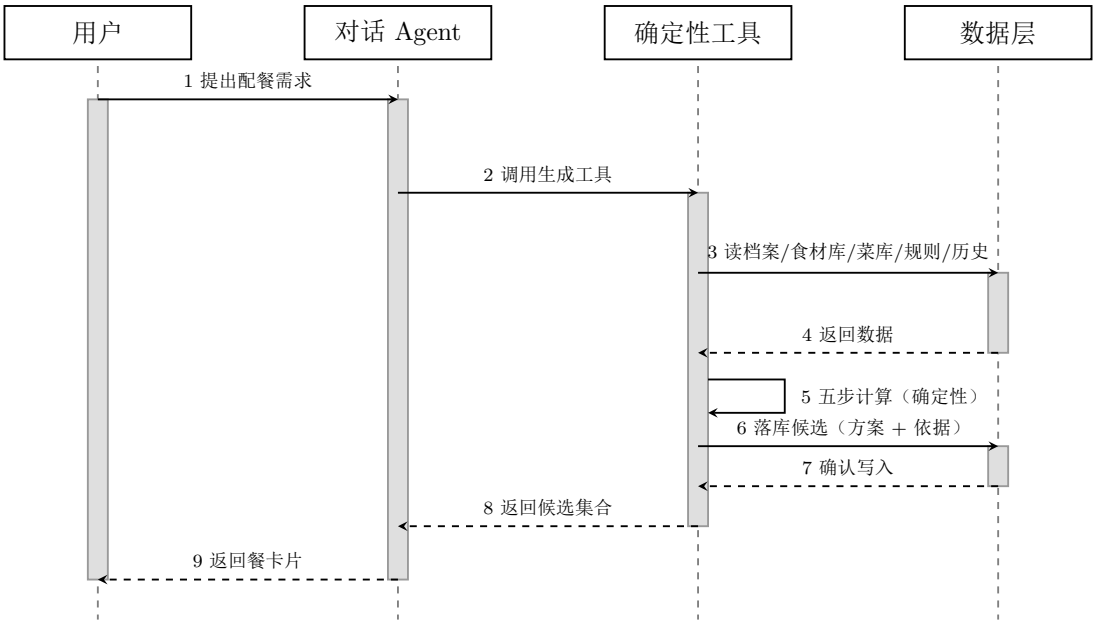


图 7: 规则引擎五步调用时序图

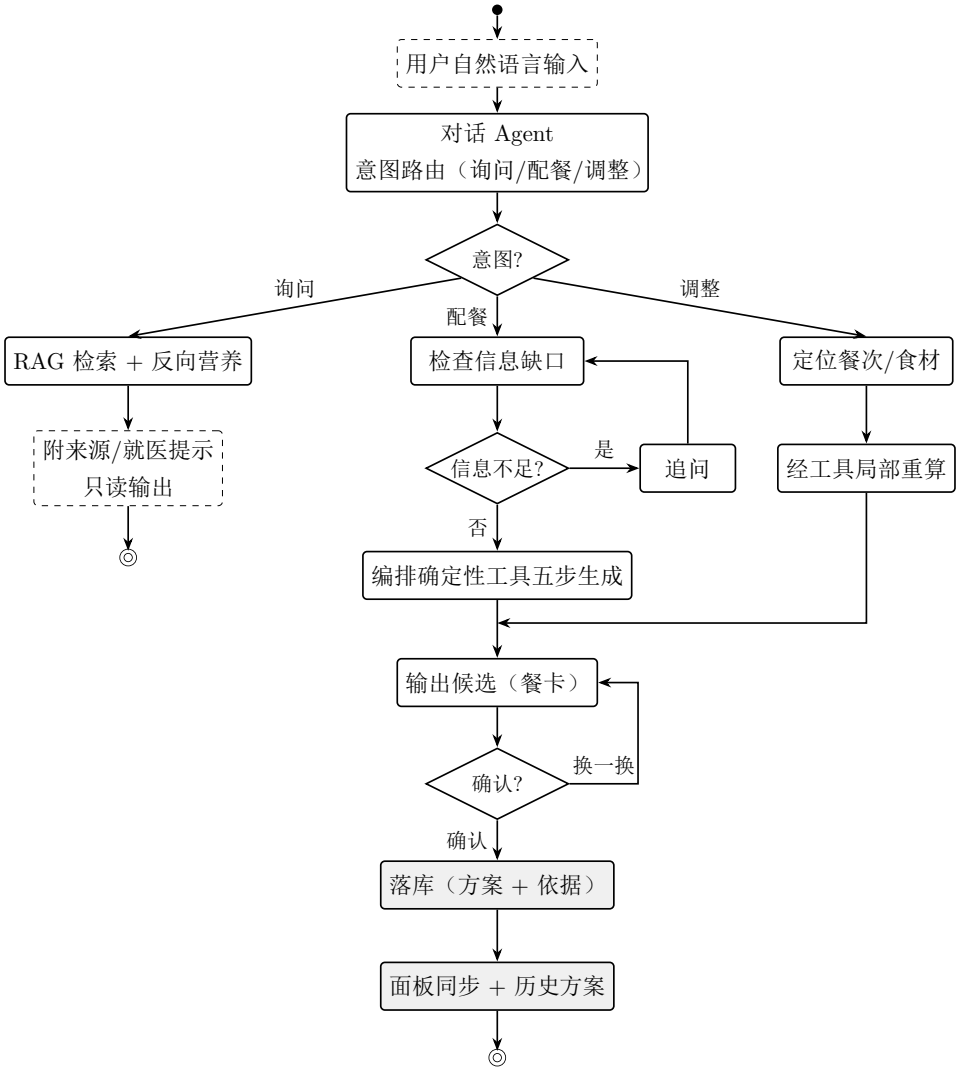


图 8: 对话 Agent 活动图（意图路由 → 工具编排 → 落库）

5.4 接口设计

5.4.1 接口标识

接口按「用户接口—外部接口—内部接口」三类划分，每类接口赋予项目唯一标识，标识范围与交互双方见表 12。

表 12: 接口标识总览

类别	前缀	标识形式	交互双方	数量
用户	IF-UI	IF-UI-01 ∼ IF-UI-03	用户 ↔ 前端界面	3
外部	IF-EXT	IF-EXT-01 ∼ IF-EXT-11	前端 ↔ 后端； 后端 ↔ 大模型、向量检索	11
内部	IF-INT	IF-INT-T01 ∼ T12； IF-INT-DB-01 ∼ 04	后端 ↔ Agent 工具层； 后端 ↔ 数据库四 Schema	16

5.4.2 用户接口

用户接口不涉及网络协议，只约定「界面提交什么、展示什么、异常如何提示」，数据来源均经 5.4.3 的外部接口取得。

1. **IF-UI-01 对话主界面**：唯一入口，单一对话界面（仿通用大模型客户端），左侧会话历史、中部对话流、底部输入框；档案维护、配餐、调整与咨询均从对话发起，意图路由（询问 / 配餐 / 调整）对用户透明。
2. **IF-UI-02 结构化输出面板**：对话右侧工具栏（可收起），含食材清单、当前规划、历史方案、膳食报告四面板，只读展示已确认方案的结构化结果；不承载「生成」动作，生成与调整均由对话发起，面板为空时引导用户回到对话发起配餐。
3. **IF-UI-03 轻量档案**：仅保留身体参数、健康目标、过敏与禁忌等影响计算的关键字段，不必一次填全；支持对话中补全（如「我乳糖不耐」），信息不足时系统追问、不作臆测；档案变更后生成结果随之联动。

5.4.3 外部接口

外部接口为后端对外提供的网络接口，统一约定：路径加 `/api` 前缀；请求 / 响应为 JSON；响应体统一为 {code, message, data}（见设计约定表 5）；JWT Bearer 鉴权，user_id 由鉴权上下文注入并按用户隔离数据。REST 接口清单见表 13，流式对话与第三方服务接口见表 14。

表 13: 外部接口（REST）清单

标识	路由	说明
IF-EXT-01	`/profile`、`/users/{id}/profile`	轻量档案 CRUD；Agent 读档案
IF-EXT-02	`/meal-plan/week/generate`、`/candidate/swap`、`/week/fix`	生成候选、换候选、固定（经确定性工具，由 Agent 触发）
IF-EXT-03	`/meal-plan/current`、`/{id}`、`/list`	当前方案 / 详情 / 历史
IF-EXT-04	`/meal-plan/{id}/nutrition`	7 关键微量跨日动态平衡 + 参考提示
IF-EXT-05	`/meal-plan/{id}/shopping-list`	按方案聚合食材清单
IF-EXT-06	`/agent/rag-query`、`/agent/reverse-nutrition`	知识库检索、反向营养推理
IF-EXT-07	`/calc/nutrition`、`/condition-rules/*`	确定性营养核算、疾病规则
IF-EXT-08	`/health`	健康检查探针

表 14: 外部接口（流式与第三方服务）

标识	接口	交互双方	说明
IF-EXT-09	`/agent/chat`（SSE）	前端 ↔ 后端	流式对话；事件 `message` / `error` / `done`，详见下节
IF-EXT-10	DeepSeek API	后端 ↔ 大模型	生成 / 对话；Function Calling + JSON 结构化输出，校验失败最多重试 3 次
IF-EXT-11	pgvector	后端 ↔ 向量检索	向量 + 关键词 RRF 混合检索；未就绪时退化为关键词检索

5.4.4 流式对话协议（SSE）

IF-EXT-09（`POST /api/agent/chat`）采用 SSE 流式传输，事件统一为 `event: <类型> + data: <JSON>`。事件类型如下：

1. `message`：正文增量，附 JSON 边车，承载来源标注、就医提示、跳转定位等结构化标记；
2. `done`：携带 `conversation_id` 与 `finish_reason`，待会话与消息落库后关闭流；
3. `error`：失败时推送统一响应对象（同 REST 约定）；已输出正文不撤回，前端在气泡末尾追加错误提示，避免「说到一半消失」。

流式对话首字延迟 $\leq$ 10s；长回答按增量推送，不阻塞前端。大模型不可用时，档案与方案浏览不受影响。

5.4.5 内部接口

内部接口为后端进程内的确定性工具接口，Agent 经 Function Calling 调用、不直连数据库，数值一律后端确定性计算。分为 Agent 工具接口（IF-INT-T01～T12）与数据库访问接口（IF-INT-DB-01～04）两类。

表 15： Agent 工具接口（IF-INT-T01～T12）

标识	工具名	用途
IF-INT-T01	搜索食材	按名称/别名查找食材及营养成分
IF-INT-T02	查询菜式营养	查菜式能量/蛋白/钠/钙与完整性
IF-INT-T03	过敏原筛查	按用户过敏原过滤菜式
IF-INT-T04	匹配营养参考值	按人群条件匹配 RNI/AI/UL
IF-INT-T05	跨日 UL 评估	跨日摄入 vs UL 超限判断
IF-INT-T06	查看疾病规则目录	规则与审核状态目录
IF-INT-T07	查询正式疾病规则	只读已审核启用规则
IF-INT-T08	执行疾病规则评估	按规则评估当日摄入
IF-INT-T09	知识库检索	膳食指南/成分表/DRIs 原文检索
IF-INT-T10	反向营养推理	症状 $\rightarrow$ 可能缺乏的营养素
IF-INT-T11	营养核算/汇总	菜品 + 份量 $\rightarrow$ 整餐/整日营养汇总
IF-INT-T12	读用户档案	读取档案

数据库访问接口按四 schema 划分：

- **IF-INT-DB-01**（core）：食材 / 菜 / 营养素 / 规则；
- **IF-INT-DB-02**（knowledge）：知识库；

- **IF-INT-DB-03**（app）：业务表 / 视图 / 函数；
- **IF-INT-DB-04**（audit）：导入批次 / 质量。

应用连接为非超级用户：core / knowledge 只读，app 读写。

6 运行设计

6.1 系统初始化

系统启动时依次完成：数据库建表（幂等）与种子数据灌入（食材库、菜库、7 关键微量目标表、健康目标 → 结构映射表、症状 → 营养素映射、营养素参考值表）；首次向量化知识库；后端服务启动并加载配置；Agent 层加载系统指令与工具注册。

6.2 运行控制

运行时按请求触发对应运行模块组合，分四条路径控制，各自按「触发—模块组合—资源占用—安全控制—失败处理」约定。

场景 A：询问（咨询 / 反向营养，只读）

- **触发**：用户以自然语言提问（搭配原理 / 症状咨询），可附历史方案引用。
- **模块组合**：前端对话界面 → `/agent/chat`（SSE）→ 对话 Agent → RAG / 反向营养 → 前端流式渲染。
- **操作步骤**： 建立/复用会话 → 读档案硬约束与引用方案 → RAG 检索 / 反向营养 → 生成正文与来源 → SSE 按 `message / done` 推送 → 会话与消息落库。
- **资源占用**：首字延迟 $\leq$ 10s，长回答增量推送不阻塞。
- **安全控制**：只读不改方案；未引用方案的回答标注「通用建议」；反向营养附就医提示；命中内容安全策略返回 `3001`。
- **失败处理**：大模型失败返回 `error` 事件（`2002`）可重试；结构化输出 3 次失败降级（`2003`）。

场景 B：配餐（生成，写入）

- **触发**：用户表达生成范围（一餐 / 一日 / 数日或更长）。
- **模块组合**：对话 Agent → 生成工具 → 规则引擎五步算法 → 数据层落库。
- **操作步骤**：按 5.1.3 规则引擎五步生成算法执行，输出候选 + 依据 + 覆盖进度。
- **资源占用**：候选生成 P95 $\leq$ 5s。
- **安全控制**：过敏 / 忌口硬排除；从全量食材库选材；大模型不参与计算。
- **失败处理**：计算异常返回 `2001`；约束冲突返回明确无解提示，不返回半成品方案。

场景 C：调整（换候选 / 追加要求，写入）

- **触发**：用户表达「换一换」「不吃某食材」「换做法」等调整诉求。
- **模块组合**：对话 Agent → 换候选 / 重算工具 → 局部重算 → 数据层回写。
- **操作步骤**： 解析调整范围 → 调换候选 / 重算工具 → 维持该餐宏量结构 → 数值更新并落库。
- **资源占用**：候选生成 P95 $\leq$ 5s；固定为单事务。
- **安全控制**：仍经确定性工具，禁忌不越界。
- **失败处理**：无解时明确提示；已固定方案不可再改（2005）。

场景 D：查看输出面板（只读）

- **触发**：用户打开输出面板。
- **模块组合**：前端 → 查询接口 → 数据层已确认方案。
- **操作步骤**：按筛选条件取方案与候选，只读聚合展示；不触发任何写操作。
- **资源占用**：确定性计算 P99 $\leq$ 100ms。
- **安全控制**：只读已确认方案，不涉及用户隐私字段外泄。
- **失败处理**：面板为空时引导用户回对话发起配餐。

6.3 运行结束

服务停止时释放数据库连接与会话资源；对话会话数据保留于数据层，用户可再次打开会话。

7 系统出错处理设计

7.1 出错信息

系统所有接口（含 SSE 流式对话的首帧）统一返回 JSON 响应对象（字段见设计约定表 5）：`code = 0` 表示成功，`code` $\neq$ `0` 表示失败，`message` 为面向用户的中文提示，不含堆栈、SQL 与内部路径。错误码分段：**0 成功；10xx 参数与权限类；20xx 计算与依赖类；3001 内容安全拦截**，同一错误码在所有接口语义一致。错误码见表 16。

表 16: 错误码表

错误码	含义	说明
0	成功	正常返回，data 承载业务数据
1001	参数错误	请求参数缺失/非法
1002	未授权	未登录或 token 失效

错误码	含义	说明
1003	越权	无权访问他人资源
1004	不存在	目标资源不存在
2001	计算失败	规则引擎/确定性计算异常
2002	Agent 调用失败	大模型调用异常，可重试
2003	结构化输出降级	结构化输出校验 ≤ 3 次失败后降级
2004	数据源不可用	数据库/向量库不可用
2005	方案已锁定	已固定方案不可再换候选
2006	未捕获异常	统一兜底，仅写日志与 audit，不回传堆栈
3001	内容安全拦截	输出命中内容安全策略

补充约定：

1. **文案单一来源**：`message` 由错误码映射表生成，禁止下游随手拼接，避免同一错误出现多种说法。
2. **业务错误 $\neq$ HTTP 错误**：HTTP 层使用 200 / 400 / 401 / 403 / 404 / 429 / 500 / 502；参数错误用 400、未授权/越权用 401 / 403、超并发或频次用 429，其余业务失败仍返回 200 + 非 0 `code`，便于前端统一拦截。
3. **流式不撤回**：失败时按 `event: error` 推送上述结构，已输出正文不撤回，前端在气泡末尾追加错误提示。
4. **前端统一兜底**：1002 统一跳登录、1004 统一展示空态、2002 与 2003 统一展示「AI 解释暂不可用」。

7.2 补救措施

出错处理遵循「**先自救、再降级、后提示**」三级策略：服务端能自动补救的不打扰用户；不能补救的降级为可用结果并留痕；确实不可用的才给出明确提示与下一步动作。

典型补救：

- 档案不存在 $\rightarrow$ 引导用户先建档，不臆造数据；
- 过敏原未核查 $\rightarrow$ 保守剔除（exclude_until_verified），不宣称安全；
- 疾病规则未审核 $\rightarrow$ 返回 rule_not_approved，不误判；
- null $\neq$ 0 $\rightarrow$ 缺失值返回「无法判断」而非按 0 判定；
- Agent 结构化输出校验失败 ≤ 3 次后降级重试（2003）；
- 工具调用失败 $\rightarrow$ 返回错误说明字符串而不抛异常，Agent 降级续跑。

兜底原则：

- **宁可少给结论，不给错结论**：未核查的营养数据不作为「安全」依据，缺失值不参与达标率计算。
- **降级必留痕**：任何降级都在响应中带 `degraded: true` 与降级原因，写入 audit 表，便于追溯与复盘。
- **不做医学诊断**：涉及症状与用药的请求一律以 `3001` 拦截并引导就医。

8 系统维护设计

8.1 检测点的设计

检测点分启动自检、运行监控、周期回归三级，见表 17。所有检测点结果写入统一观测口径（字段：检测点、时间、结果、耗时、trace_id），评测层按周汇总候选达标率、结构化输出成功率与响应时延。

表 17: 检测点清单

级别	检测点	目的
启动自检	数据库建表 / 种子数据 / 向量化完成、健康检查就绪	失败拒绝启动，不带缺陷上线
运行监控	健康检查探针、候选生成时延、确定性计算时延、Agent 结构化输出成功率、RAG 命中/可溯源、数据库连接状态	异常触发告警
周期回归	数值口径、工具契约、边界场景回归脚本	验证「算得对」而非仅「存活」

8.2 检测专用模块的设计

8.2.1 健康检查接口

`GET /api/health` 返回统一响应对象，其 `data` 字段含 `db`、`vector`、`agent`（布尔探针）、`version`（字符串版本号）、`degraded`（布尔降级标记）；三个探针各自执行一次轻量操作（`SELECT 1` / 向量库计数 / 模型握手），超时 500ms 判为 false。存活与就绪分离：

- `/api/health/live`：仅证明进程存活，供容器重启判定；
- `/api/health/ready`：要求三个依赖全为 true，供负载均衡摘流使用。

向量检索未接线期间 `vector` 记为 `not_applicable` 且不参与 ready 判定；该接口为运维探针，不计入业务接口清单。

8.2.2 数据库验收脚本

`scripts/verify_db.py`，只读、可重复执行，依次校验：schema 是否存在 → 表与字段是否齐全 → 外键与唯一约束是否生效 → 种子数据行数是否达下限 → 向量维度与 chunk 数是否对齐。输出机器可读 JSON 报告，**退出码非 0 即判定验收失败**，可直接接入部署流水线；配套 `init_db + seed` 必须幂等，可作为回滚后的重放手段。

8.2.3 结构化日志

- **分级**：DEBUG（工具入参与出参）、INFO（请求与关键状态迁移）、WARN（降级、重试、约束放宽）、ERROR（未捕获异常、依赖不可用）。
- **结构化**：JSON 单行输出，字段固定为 `ts / level / trace_id / user_id`（脱敏）/ `module / code / latency_ms / msg`。
- **链路串联**：`trace_id` 由接口层生成，透传至 Agent、工具调用与数据库访问，一次请求全链路回溯。
- **脱敏**：手机号、身份证、疾病信息等敏感字段落日志与入库前统一脱敏，原始值只存于加密列；日志不含完整个人资料与密钥。

8.2.4 监控指标

采集四类指标并按层打标（接口层 / Agent 层 / 规则引擎层 / 数据层），定位退化发生在哪一层：流量（QPS、并发会话数、429 触发次数）、时延（P50 / P95 / P99、首字延迟）、错误（错误码分布、工具调用失败率、降级率）、成本（大模型 token 消耗与调用次数）。评测层与运行监控共用同一份数据，不另起一套报表。

8.2.5 回归测试脚本

以固定档案构造基准用例，覆盖三类：**数值口径**（BMR、TDEE、默认三餐宏量 30/40/30、供能比换算、1g 油脂 = 9kcal）、**工具契约**（入参拼装、URL 与方法、业务错误码与网络异常下的降级分支）、**边界场景**（空档案、过敏原冲突、全量食材库中约束无解）。脚本以测试桩替代真实后端与模型，提交前执行，**退出码作为门禁**，确保局部改动不破坏既有功能。

9 尚待解决的问题

本节列出本设计尚未解决、且系统完成前需解决的问题。

表 18: 尚待解决问题

编号	尚待解决的问题	完成前需解决的要点
P1	反向营养的确定性方案未定：症状 → 营养素目前仅「推测＋就医提示」，是否纳入确定性推理、映射表覆盖范围未定	明确反向营养是交付功能还是仅参考线索；若交付则补确定性映射
P2	营养核算数据口径未定：菜式油盐糖为量级估计，可食部、烹饪损失未落定	定数据源与换算口径，使数值精度可接受且可溯源
P3	硬约束冲突时求解策略未定：候选为空时放松顺序、优先级、终止与兜底未定义	明确无解降级策略，保证算法必终止、结果可解释
P4	低质量数据兜底策略未定：食材「估算/待核查」占比高时如何出方案、如何提示未定义	明确低质量数据下的可用性与提示口径

10 需求的可追踪性

系统部件（CSCI-01～06，见 5.2）与系统需求（MVP 验收标准 7 条）建立双向追踪，正向见表 19，反向见表 20。

表 19: 需求可追踪性（正向：验收标准 → 部件）

编号	MVP 验收标准	满足部件
1	自然语言表达生成范围，正确路由并生成	CSCI-01（对话入口）、CSCI-03（意图路由） CSCI-04（五步生成）
2	表达约束时方案不含相关食材，信息不足时追问而非臆测	CSCI-01（档案交互）、 CSCI-03（needs_clarification 追问） CSCI-04（硬排除）
3	数值来自确定性工具且可溯源，换候选后数值更新并真实落库	CSCI-02（接口）、CSCI-06（落库）、 CSCI-04（确定性工具）
4	确认后落库，面板同步，历史方案可回看	CSCI-01（输出面板）、CSCI-06（落库）、 CSCI-02（查询接口）
5	询问类问题附来源，反向咨询附就医提示	CSCI-03（解释与就医提示）、 CSCI-05（RAG 溯源）
6	档案变更后生成结果随之联动	CSCI-04（生成读档案）、CSCI-06（档案）

编号	MVP 验收标准	满足部件
7	读取近期历史做微量跨日平衡，无历史时追问或放松约束	CSCI-03（追问）、CSCI-04（五步第 4 步）、CSCI-06（历史方案）

表 20: 系统部件到需求的反向追踪（部件 → 验收标准）

部件	覆盖验收标准
CSCI-01 前端对话界面（含输出面板）	1、2、4
CSCI-02 后端服务（接口层）	3、4
CSCI-03 对话 Agent	1、2、5、7
CSCI-04 规则引擎（确定性工具）	1、2、3、6、7
CSCI-05 知识库（RAG）	5
CSCI-06 数据库（含轻量档案）	3、4、6、7